



Universidade de São Paulo
Faculdade de Economia, Administração, Contabilidade e Atuária

**Fraudes Corporativas no Brasil: Atuação da CVM no
Enforcement do Arcabouço Regulatório-Legal dos Mercados de
Capital**

Relatório Final de Iniciação Científica

Nome: Tomás Peres Ribeiro

Orientador: Prof. Dr. Dante Aldrighi

Resumo

Esta pesquisa investiga as fraudes corporativas no Brasil por meio de ferramentas desenvolvidas para a análise sistemática dos Processos Administrativos Sancionadores (PAS) conduzidos pela CVM entre 2000 e 2023. Focaliza especificamente casos de expropriação de acionistas minoritários por controladores e seus subordinados. Diante do volume extenso de processos (mais de 2.100), o estudo adotou técnicas de Processamento de Linguagem Natural (PLN) para a classificação automática dos documentos: desenvolveu-se um *pipeline* para lidar com os dados, um *corpus* anotado com critérios objetivos para variáveis de interesse e criou-se uma infraestrutura de dados abrangente, incluindo informações sobre os PAS disponíveis publicamente. Os resultados representam a primeira tentativa de sistematização metodológica para a aplicação de PLN a documentos regulatórios da CVM.

Abstract

This research investigates corporate fraud in Brazil through tools developed for the systematic analysis of Administrative Sanctioning Proceedings (PAS) conducted by the Brazilian Securities and Exchange Commission (CVM) between 2000 and 2023. It focuses specifically on cases of expropriation of minority shareholders by controlling shareholders and their subordinates. Given the extensive volume of proceedings (over 2,100), the study adopted Natural Language Processing (NLP) techniques for the automatic classification of documents: a pipeline was developed to handle the data, a corpus was annotated based on objective criteria for variables of interest, and a comprehensive data infrastructure was created, including information on publicly available PAS. The associated results represent the first attempt at methodological systematization for applying NLP to these regulatory documents.

1. Introdução

Embora o Decreto-lei nº 157, de 1967, tivesse o objetivo de incentivar a captação de recursos via emissão de ações de modo a sustentar a expansão de investimentos produtivos (Correa do Lago 1989, p. 74), o resultado, dado o contexto da fraca regulamentação dos mercados de capitais, foi a alta artificial dos preços das ações, “culminando com um *boom* especulativo seguido de um traumático processo de reajuste em 1971” (Costa 1985, p. 41-2). Esse processo envolveu esforços para criar um arcabouço regulatório dos mercados de capitais e assegurar sua observância, de modo a proteger os investidores e proporcionar transparência nas informações das companhias.

Em 1976, instituiu-se a Lei nº 6385, que dispõe sobre o funcionamento do mercado de capitais no país (Brasil 1976), e criou-se a Comissão de Valores Mobiliários (CVM), autarquia vinculada ao Ministério da Fazenda, “com o objetivo de fiscalizar, normatizar, disciplinar e desenvolver o mercado de valores mobiliários no Brasil” (CVM 2024).

Os Processos Administrativos Sancionadores (PAS), regulados pela Resolução nº 45 da autarquia, de agosto de 2021, constituem o principal instrumento de *enforcement* das normas da CVM e também da legislação referente às empresas de capital aberto. Detectada uma ilegalidade, por quaisquer meios, a CVM pode instaurar um PAS, com base nos termos do Art. 5º (CVM 2021); os acusados são notificados e podem apresentar defesa; definido um relator por sorteio, realiza-se uma Sessão de Julgamento, conduzida pelo Presidente da CVM, em que cada membro do Colegiado¹ tem direito a voto, sendo as deliberações tomadas por maioria. A CVM tem a prerrogativa de impor penalidades, isolada ou cumulativamente.

Em qualquer momento do andamento de um PAS, os acusados podem apresentar uma proposta de Termo de Compromisso (TC), pela qual se comprometem a cessar a prática de atividades consideradas ilícitas e, se for o caso, ressarcir os prejuízos imputados. Após recomendação do Comitê de Termo de Compromisso (CTC)², o Colegiado delibera se aceita ou não a proposta de TC apresentada. No caso de aceitação e cumprimento da proposta de TC pela parte acusada, o PAS é suspenso.

A despeito dos grandes avanços na governança das empresas propiciados por importantes mudanças institucionais (como as reformas na lei das S.A. de 2001 e na lei relativa a títulos mobiliários de 2002, que fortaleceu a CVM; e a criação pela B3, em 2000, de

¹ O Colegiado da CVM é formado por um Presidente e quatro Diretores, nomeados pelo Presidente da República e aprovados pelo Senado Federal.

² O CTC é formado pelos titulares de cinco ou mais Superintendências da CVM (normalmente funcionários de carreira, que devem possuir pós-graduação na área), indicados pelo Presidente, além do titular da Procuradoria Federal Especializada na CVM (PFE-CVM).

segmentos de listagem diferenciados de governança das empresas), fraudes corporativas (FCs) têm sido recorrentes nos mercados de valores mobiliários no Brasil. Parcela expressiva dos malfeitos corporativos concentra-se em casos de expropriação de acionistas minoritários por acionistas majoritários (controladores) e prepostos.

Com base no exame sistemático das informações disponíveis nos PAS e nos TCs da CVM de 2000 a 2023, esta pesquisa visa construir uma base de dados sobre os casos envolvendo esse tipo específico de malfeito corporativo. Essa base de dados será posteriormente usada para relacionar a ocorrência de FCs com características das companhias e mudanças institucionais.

A construção dessa base de dados exige a análise de mais de 2000 processos para extrair dados e informações de variáveis de interesse (como valor das multas/TCs, tipo de malfeito, cargo dos acusados ou compromitentes etc.). Esses desafios práticos para lidar com a grande quantidade de dados linguísticos impuseram uma reorientação metodológica: o uso de ferramentas de aprendizado de máquina (ou *machine learning*, como são conhecidas mais popularmente), na área de Processamento de Língua Natural, com o objetivo de classificar automaticamente variáveis de interesse relacionadas aos processos. Isso implicou a construção e anotação de um *corpus* para aplicações na área de FCs no Brasil e o treinamento de modelos de classificação a serem empregados neste *corpus*, como especificado em seções posteriores.

Houve, portanto, uma reorientação nos objetivos da pesquisa, que viabilizou uma coleta de dados mais abrangente, contemplando um número maior de processos, além de garantir que os resultados produzidos pudessem extrapolar os limites imediatos da investigação, oferecendo subsídios para aplicações e análises complementares em pesquisas futuras (um *corpus* e *insights* sobre treinamento e qualidade dos modelos). Essa contribuição metodológica constitui um passo no entendimento dos fatores que influenciam a ocorrência de FCs e, portanto, para identificar possíveis mecanismos de governança que as inibam ou as impeçam, gerando ferramentas e evidências para investigar questões de interesse acadêmico e de *policy-makers*.

2. Referencial Teórico

2.1. O arcabouço teórico

A persistência das fraudes corporativas no país pode ser entendida pela ótica do

clássico modelo econômico do crime de Becker (1968), em que o agente confronta as utilidades esperadas do ato criminoso e do emprego de tempo e outros recursos em atividades alternativas (como o trabalho remunerado lícito). Isso implicaria, portanto, na “existência de uma função que relaciona o número de ofensas cometidas por uma pessoa com a sua probabilidade de ser condenado, a sua pena, caso condenado, e outras variáveis, como a renda disponível em outras atividades (legais e ilegais) e sua disposição pessoal em cometer um ato ilícito.” (Becker 1968, p. 9).

Outra vertente, a Teoria da Agência, formulada por Jensen e Meckling (1976), focaliza mais claramente alguns elementos que interferem nas utilidades esperadas dos indivíduos no contexto da firma. Segundo essa teoria, a relação de agência ocorre quando um indivíduo ou grupo (o principal) contrata outro indivíduo ou grupo (o agente) para desempenhar uma atividade em seu nome, delegando-lhe algum grau de poder de decisão. A delegação de autoridade dos acionistas para os executivos, embora essencial para a operação eficiente das empresas, cria um “problema de agência” devido ao desalinhamento potencial entre os interesses do principal e do agente.

Como os gestores possuem informações mais detalhadas sobre a empresa do que os acionistas minoritários (assimetria informacional), podem tomar decisões que maximizam seu próprio bem-estar às custas dos acionistas minoritários, como adotar projetos de menor risco para preservar seus empregos e manipular resultados contábeis para maximizar bônus de desempenho. Nesse contexto, surgem os custos de agência, que representam a soma dos custos relacionados ao problema de agência: as perdas diretas decorrentes da extração de benefícios privados pelos executivos que destroem valor corporativo, adicionadas às despesas incorridas para inibir tal comportamento oportunista.

Os autores atribuem grande peso ao papel da estrutura de propriedade na intensidade do problema de agência. Na relação de agência, o monitoramento dos executivos é um bem público, que exige esforço de cada acionista, que, no entanto, não têm incentivo individual para exercê-lo, uma vez que o custo incorrido para o monitoramento é individual e o benefício se estende aos demais acionistas (*free-riding*). Nesse caso, portanto, a concentração da propriedade pode mitigar o conflito de agência, uma vez que acionistas com participação significativa internalizam uma parcela maior dos benefícios decorrentes do monitoramento da gestão, reduzindo o problema de *free-riding* e incentivando a supervisão ativa dos executivos, reduzindo assim comportamentos oportunistas e garantindo que as decisões de gestão estejam alinhadas com os interesses da empresa.

Zingales (2002) analisa os problemas de agência pela ótica dos contratos incompletos.

Como os contratos são podem contemplar todas as contingências futuras, não se pode especificar plenamente o que cada agente (executivo) deve fazer no futuro, o que lhes confere poder discricionário que pode ser usado para extrair benefícios privados da empresa em detrimento dos acionistas.

Além disso, cada *stakeholder* realiza investimentos específicos na empresa, tornando suas transações únicas e não padronizadas. Isso gera *quasi-rents* (excedentes) cuja divisão não pode ser determinada antecipadamente por contrato. Assim, ocorre uma barganha *ex post* entre as partes envolvidas. A governança corporativa, portanto, consiste no conjunto de regras que molda como o poder e os incentivos e, consequentemente, as *quasi-rents* são distribuídos entre os *stakeholders*. A atuação da CVM e outras características institucionais, como parte do ambiente de governança corporativa no Brasil afetam, portanto, a ocorrência de FCs no país.

À luz dessas referências teóricas, pretende-se investigar a ocorrência de FCs com base nos PAS em que se acionistas controladores e seus subordinados são suspeitos de expropriarem acionistas minoritários.

A fundamentação teórica discutida acima (modelo econômico do crime de Becker, teoria da agência e teoria dos contratos incompletos) serve de guia de referência para a interpretação dos processos conduzidos pela CVM e permite avaliar em que medida tais teorias se adequam ao *data generating process* associado às FCs no Brasil. Adotar essa perspectiva teórico-analítica possibilita uma investigação metodologicamente orientada, de modo a garantir rigor e consistência na interpretação dos casos.

2.2. Trabalhos relacionados

Embora recorrentes, as FCs têm sido pouco investigadas no país, em contraste com a copiosa literatura para mercados desenvolvidos, como Estados Unidos e União Europeia.

Dyck, Morse e Zingales (2010) investigam a identidade, características e incentivos dos *whistleblowers* que denunciam práticas ilícitas nas empresas norte-americanas. A base de dados que utilizam contém variáveis sobre o tipo de denunciante (se autoridades regulatórias dos mercados de capital ou setoriais, auditores, jornalistas, empregados etc.), seus incentivos (profissionais, reputacionais e monetários) e o grau de acesso a informações privilegiadas. Obtêm evidências da importância, entre os denunciantes, de agentes não convencionais (mídia e funcionários das empresas) *vis-à-vis* aqueles cuja atribuição de ofício é exercer tal monitoramento, como órgãos reguladores e fiscalizadores e auditores. Além disso, analisam

com detalhe os incentivos e *tradeoffs* enfrentados por categoria de denunciante (por exemplo, no caso de o *whistleblower* ser um funcionário da empresa, o risco de perder o emprego ou de ser relegado ao ostracismo pelos colegas). Observam que os incentivos monetários são especialmente importantes para os funcionários do setor de saúde e os incentivos reputacionais, para jornalistas.

Wang (2013) e Dyck, Morse e Zingales (2023) estimam a probabilidade de detecção de FCs a partir de medidas de fraudes observadas. Dyck, Morse e Zingales (2023) recorrem a um experimento natural: após um escândalo em uma auditoria, as empresas que eram anteriormente suas clientes passaram a ser mais fiscalizadas, o que aumentou o grau de FCs detectadas. A partir disso, os autores estimam que somente um terço das fraudes corporativas é detectada.

Por sua vez, Johnson, Ryan e Tian (2009) focalizam os incentivos dos executivos e a probabilidade de ocorrência e detecção de FCs. Utilizando uma base de dados construída a partir de informações sobre os malfeitos investigados pela *Securities and Exchange Commission* (SEC), a CVM norte-americana, entre 1992 e 2005, realizam o pareamento (*matching*) com empresas não-fraudulentas e encontram evidências de que malfeitos corporativos tendem a ser mais frequentes em empresas cuja remuneração dos executivos é atrelada preponderantemente ao desempenho das ações, resultados consistentes com Becker (1968).

Karpoff et al. (2017) identificam quatro bases de dados entre as mais utilizadas para estudar FCs nos Estados Unidos, examinando as vantagens e desvantagens de cada uma delas. Chamam atenção para os cuidados que se devem ter ao utilizá-las e para a importância dos dados colhidos manualmente “para aliviar os problemas que surgem quando uma base de dados ou uma variável proxy em específico é utilizada para identificar uma amostra de malfeitos ocorridos” (Karpoff et al. 2017, p. 43). Enfatizam, também, a importância da replicabilidade da construção das bases de dados e a relevância de que tenham uma construção iterativa. Como os resultados são muito sensíveis à base de dados utilizada, recomendam testes de validação externa para as bases de dados construídas.

Os trabalhos acima fundamentaram-se em bases de dados de FCs nos Estados Unidos. O contexto corporativo brasileiro, por apresentar características institucionais únicas, como alta concentração de propriedade do capital e arcabouço regulatório e mecanismos de *enforcement* menos robustos, torna imprescindível uma análise de suas especificidades.

Aldrighi (2011) e Aldrighi e Kabback de Castro (2023) empreendem estudos empíricos descritivos sobre FCs no país, focalizando um número limitado de empresas e empregando informações de diversas fontes, o que permite um entendimento mais aprofundado de casos específicos. Callund, Jiménez-Seminario e Pyper (2023) examinam o contexto institucional de alguns países da América Latina. Alguns trabalhos fazem um esforço no sentido de construir relações parecidas para o Brasil, embora usem bases de dados menos abrangentes. O Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap), da FGV-SP, divulga relatórios anuais sobre os PAS conduzidos pela CVM (MFCap 2019, 2021, 2022, 2023), categorizando todas as ocorrências julgadas pela CVM e organizando os dados pela perspectiva jurídica para os anos de 2019, 2021, 2022 e 2023. Diferentemente, o presente trabalho tem como propósito explorar de modo detalhado o conjunto das informações disponíveis pelo recorte específico de tentativas de expropriação de acionistas minoritários pelos acionistas controladores para um período de 24 anos (2000-2023).

3. Metodologia

3.1. Planejamento original

O objetivo original da pesquisa era construir uma base de dados sobre FCs nas empresas brasileiras a partir do exame sistemático dos processos administrativos sancionadores da CVM e dos termos de compromisso celebrados entre suspeitos de cometerem irregularidades nos mercados de capitais e a autarquia, o que envolveria a extração manual de variáveis de interesse para cada um dos processos.

A estratégia inicial envolvia três etapas de processamento manual dos dados linguísticos:

1. Classificação de relevância³: para todos os processos, classificar o que neste trabalho se convencionou chamar de “relevância” – se o processo tem relação com a ocorrência de FCs, podendo, portanto, ser analisado sob a ótica do arcabouço teórico exposto anteriormente, ou seja, se está conectado com a suspeita de expropriação de acionistas minoritários pelos controladores ou seus subordinados;

³ Ao longo do trabalho, a convenção usada para definir “relevância” de um processo é se ele tem ou não relação com as FCs.

2. Delimitação das variáveis: definição das variáveis a serem extraídas dos processos, adotando-se critérios claros para cada uma e também para os grupos categóricos das variáveis qualitativas (ex: “tipo de infração”);
3. Extração manual: extrair dos textos os valores correspondentes para cada uma das variáveis selecionadas.

É importante ressaltar que, durante este procedimento metodológico, o conceito de "relevância" dos processos constituía o filtro fundamental da pesquisa: apenas processos conectados com suspeitas de expropriação de recursos de acionistas minoritários pelos controladores seriam incluídos na base final, excluindo-se assim irregularidades relacionadas, por exemplo, à má gestão de fundos, inadequações contábeis meramente formais, ou problemas operacionais sem impacto distributivo entre acionistas.

A abordagem inicial pretendia gerar uma base de dados granular e abrangente que permitisse investigações econométricas sobre os fatores determinantes das FCs no Brasil, com base no arcabouço teórico apresentado anteriormente, preenchendo uma lacuna importante na literatura acadêmica nacional.

3.2. Desafios identificados e reorientação

O andamento da pesquisa evidenciou que o método de extração manual seria essencialmente inviável: computou-se um total de aproximadamente 2100 PAS a serem organizados. Tendo em vista o tempo necessário para leitura e extração das variáveis, que, na raiz, tem relação com o grande volume de dados, apresentou-se um *tradeoff*: a opção pela extração manual significaria incorrer em uma redução na quantidade de processos analisados.

Este *tradeoff* motivou a escolha de métodos de Processamento de Língua Natural para tratamento dos dados linguísticos. São três as principais considerações estratégicas a este respeito. Em primeiro lugar, o uso de ferramentas de PLN permitiria processar as grandes quantidades de informação de maneira mais eficiente, possibilitando uma abordagem mais abrangente dos PAS. Em segundo lugar, abriu-se a possibilidade de fazer contribuições associadas ao desenvolvimento de ferramentas metodológicas replicáveis, como a construção e anotação de um *corpus*, informações sobre a performance dos modelos (tanto comparativamente, entre eles, quanto de maneira absoluta) e construção de um *pipeline*⁴ para servir como base para análises similares. No contexto desse trabalho, ele abrange desde a

⁴ Pipeline é o nome dado à sequência estruturada de etapas de processamento, em que a saída de cada fase serve de entrada para a seguinte, permitindo a execução modular, reproduzível e integrada de tarefas.

coleta dos documentos originais em formato PDF, a extração e seleção dos trechos relevantes de texto, o processo de anotação manual, até as fases de pré-processamento, transformação, modelagem e classificação automática dos casos.

A reorientação metodológica não apenas preservou o objetivo central da pesquisa, como revelou uma oportunidade de contribuição mais ampla e estrutural. A transição de métodos manuais para PLN evidencia um problema sistêmico no estudo quantitativo de documentos regulatórios brasileiros: a escassez de ferramentas metodológicas que permitam análises em larga escala de textos jurídico-administrativos. Ao desenvolver um *pipeline* replicável e um *corpus* anotado, a pesquisa endereça essa lacuna fundamental, criando infraestrutura que pode ser apropriada por outros pesquisadores interessados em fenômenos similares no mercado de capitais brasileiro. Mais do que isso, a abordagem metodológica desenvolvida visa demonstrar como técnicas de PLN podem ser adaptadas às especificidades do contexto regulatório nacional, considerando não apenas as particularidades linguísticas do português jurídico, mas também as características institucionais específicas da CVM. Esta contribuição metodológica tem potencial para catalisar uma linha de pesquisa mais robusta sobre o enforcement regulatório no Brasil.

3.3. Nova abordagem: uso de PLN para classificação dos PAS

O objetivo primordial da escolha de ferramentas de PLN é classificar os processos nas categorias “relevante” ou “não relevante”, conforme especificado anteriormente, mas é possível estender o uso para outras aplicações, como, por exemplo, a classificação de variáveis categóricas.

O emprego dessas ferramentas exige, em primeiro lugar, a construção do *pipeline* a ser seguido, que descreve como e de qual fonte os textos serão extraídos, processados e classificados e será descrito nessa seção. A partir dessa sequência metodológica, é possível aplicá-la para construir o *corpus* para treinamento e teste dos modelos e, depois, na cadeia de etapas de processamento textual, viabilizando a extração e análise de informações a partir de dados textuais brutos.

Construção do *corpus*

O *corpus* deve ser construído a partir das informações disponíveis nas fontes oficiais da CVM. Para isso, optamos pela extração dos relatórios dos Extratos das Sessões de Julgamento (ESJs) e dos Pareceres do CTC. Isso pressupõe que, para todos os processos com

potencial sancionador iniciados pela CVM, exista ao menos um desses documentos, o que parece factual, já que os processos terminam em condenação ou absolvição dos acusados (o que implica um ESJ) ou em firmamento de um TC (o que implica um Parecer do CTC).

Dadas as diferenças dos dois tipos de documentos,⁵ optou-se pela extração apenas do relatório para a construção do *corpus* para padronizar as informações que seriam usadas para treinar os modelos. Além disso, o relatório contém o cerne das informações procedimentais do processo, ou seja, especifica o ocorrido e como os suspeitos estiveram envolvidos – a parte mais relevante quando se visa classificar se o processo teve relação com a expropriação de minoritários.

Os relatórios foram extraídos usando técnicas de *web-scraping* aplicadas ao site oficial da CVM. Utilizaram-se códigos em *Python* para o *download* dos Pareceres do CTC; os ESJs já estavam disponíveis para *download* na página. A partir disso, utilizou-se o pacote *pdfplumber*⁶ para extrair o texto dos arquivos e o relatório foi delimitado por expressões regulares. Extraíram-se, dessa forma, os relatórios para todos os PAS disponíveis.

Na sequência, selecionou-se uma amostra dentre os processos, com o cuidado de garantir sua representatividade em termos temporais pela extração de quantidades proporcionais de processos que foram julgados (ou cujos TCs foram firmados) para cada ano. Isso é importante pois sabe-se que ao longo dos anos a composição do Colegiado muda, o que pode alterar detalhes nos ESJs e Pareceres do CTC.

A amostra foi então anotada manualmente, de acordo com os critérios definidos no Manual de Anotação – documento cujo objetivo é transformar critérios qualitativos de relevância em critérios linguisticamente objetivos. A anotação foi conduzida por uma única pessoa, em um processo iterativo de refinamento dos critérios (casos omissos exigiram adaptações no manual de anotação). Os casos limítrofes ou ambíguos foram sinalizados em uma coluna.

A etapa de construção do *corpus* neste projeto foi orientada pelas diretrizes metodológicas apresentadas por Grimmer, Roberts e Stewart (2022), que oferecem um referencial abrangente para a transformação de textos em dados passíveis de análise, com ênfase na definição rigorosa de critérios de seleção e anotação, bem como na preocupação com a validade e a replicabilidade dos rótulos. O desenvolvimento do *corpus* buscou

⁵ Em geral, os pareceres do CTC são mais curtos e os ESJs têm registrados neles os votos dos membros do Colegiado, além do relatório.

⁶ Disponível em: <https://github.com/jsvine/pdfplumber>.

assegurar representatividade e clareza nas categorias estabelecidas, de modo a fornecer uma base empírica sólida para a aplicação dos modelos.

Etapas do treinamento dos modelos de classificação

Construído o *corpus*, procede-se ao treinamento e aplicação dos modelos com base nos dados linguísticos. Para isso, desenhou-se, com base na literatura, as seguintes etapas:

1. Pré-processamento do texto, de forma a torná-lo mais legível pelos modelos, o que envolve:
 - a. Normalização dos textos: remoção de *stopwords*, pontuação, caracteres especiais, links etc.;
 - b. Tokenização dos documentos: divisão do texto em unidades menores (*tokens*), que podem ser frases, palavras, subpalavras;
 - c. Criação de representações numéricas dos tokens – *Bag of Words*, TF-IDF etc.;
2. Divisão em conjuntos de treino e teste na proporção 80/20, de forma a possibilitar o uso de validação cruzada para obter maior robustez nos resultados;
3. Treinamento dos modelos cabíveis com base nas observações do conjunto de treino;
4. Avaliação dos modelos por métricas de performance (acurácia, *f1-score* e precisão) e da matriz de confusão, comparando com o modelo de referência (*baseline*);
5. Seleção de um ou mais modelos para aplicar ao restante do *corpus*.

A construção dessa sequência se baseia em Gentzkow, Kelly e Taddy (2019), que oferecem um *survey* abrangente sobre métodos de aprendizado de máquina aplicados às ciências sociais. O trabalho dos autores sistematiza desde a escolha do modelo adequado para diferentes finalidades analíticas até as estratégias de *fine-tuning*. A abordagem proposta neste projeto segue essa linha, combinando modelos supervisionados e não supervisionados, avaliando métricas clássicas de desempenho e realizando otimizações de hiperparâmetros, em consonância com as boas práticas apresentadas pelos autores.

4. Resultados

Em relação aos resultados deste projeto, é importante mencionar que as bases de dados, o *corpus* e os códigos associados estão disponíveis no repositório do projeto, que pode ser acessado neste [link](#) e é atualizado quando dados relevantes são adicionados.

4.1. Desenvolvimento do *corpus* e critérios de anotação

Em relação à construção do *corpus*, extraíram-se os relatórios para todos os 1993 processos em que estavam disponíveis, dos quais 43 vieram da extração de dados de PDFs escaneados, diminuindo sua confiabilidade. Construiu-se, então, a coluna de dados linguísticos do *corpus* que abrange todos os processos disponíveis no site da CVM – encerrados em julgamento ou em celebração de um TC.

O objetivo da etapa de anotação, classificar as variáveis de interesse para 600 processos, foi concluído, até o momento, para 100 processos para as seguintes variáveis:

1. Relevância: se o processo teve ou não relação com a expropriação de minoritários;
2. Existência de punição: se um ou mais acusados foram punidos;
3. Tipo de punição: pecuniária ou não-pecuniária.

A distribuição dessas variáveis para os processos anotados está especificado na Tabela

1. O histograma com a quantidade de palavras por documento está no Gráfico 1.

Variável	Categoria	Freq. Absoluta	Freq. Relativa
Relevância	Sim	42	42,9%
	Não	56	57,1%
Existência de Punição	Sim	47	48%
	Não	51	52%
Tipo de Punição	Pecuniária	36	76,6%
	Não-pecuniária	11	23,4%

Tabela 1: frequências absolutas e relativas das variáveis de interesse⁷.

É relevante ressaltar que as duas últimas variáveis foram adicionadas devido ao custo baixo de coletá-las por poderem ser usadas para o treinamento de modelos de classificação

⁷ Dentre os 100 processos classificados, um não tinha relatório disponível e um estava escaneado.

alinhados com o que tem sido feito na área de análise de textos jurídicos por algoritmos de PLN.

Outra contribuição foi a própria redação de um manual de anotação, desenvolvido iterativamente com base na análise de todos os processos anotados. Os critérios especificados transformam as categorias das variáveis em critérios linguísticos objetivos (por exemplo, respondem à pergunta “o que precisa aparecer no texto do processo para que seja considerado ‘relevante’?”). Isso permite replicabilidade e objetividade na anotação, inclusive com a possibilidade de adicionar mais anotadores em rodadas posteriores. O documento especifica exemplos.




Gráfico 1: Histograma que representa o comprimento dos documentos analisados no *corpus*.

4.2. Implementação dos modelos e resultados

Considerando que a etapa de treinamento e avaliação do modelo exige uma quantidade mínima de textos anotados para render resultados robustos, optou-se por treinar o modelo quando o máximo de observações anotadas estiver disponível no *corpus*, ou seja, quando o processo de anotação for concluído para mais textos do que no momento de finalização do relatório. O motivo dessa decisão reside no fato de que o treinamento dos modelos é uma etapa relativamente rápida.

O resultado provavelmente consistirá em estatísticas iniciais sobre as performance dos modelos, disponibilizadas nos códigos do repositório do projeto. Preferiu-se esta abordagem para garantir que os resultados sejam mais robustos, por serem produzidos a partir de um número maior de textos para treinamento.

4.3. Infraestrutura de dados e produtos complementares

No processo de construção e anotação do *corpus* e treinamento dos modelos, geraram-se algumas realizações que, embora não se relacionem diretamente ao objetivo da pesquisa, tem interesse acadêmico para pesquisas futuras.

Primeiro, desenvolveram-se *scripts* em *Python* que extraíram o ID de todos os processos cujas ESJs ou Pareceres do CTC estavam disponíveis (estimou-se o número de processos em 2094, com perda do relatório para 101 processos). A lista de acusados foi extraída para 2060 processos, com a estimativa do limite inferior do número de acusados em 8422. A data do julgamento ou da publicação do Parecer do CTC foi obtida para 1948 processos; assunto/ementa, para 1197; e a decisão, para 1075 processos. Além disso, as informações foram organizadas no repositório do projeto de maneira a facilitar o acesso e permitir replicabilidade.

4.4. Contribuições metodológicas

Para além dos resultados obtidos, cabe destacar que esta pesquisa constitui a primeira aplicação sistemática de PLN a documentos regulatórios da CVM, podendo servir como *baseline* ou referência para aprofundamentos posteriores, que serão facilitados pela elaboração de um *pipeline* replicável.

Existe a possibilidade de oferecer também uma comparação entre a performance de vários modelos de classificação aplicados a um *corpus* pequeno mas com textos extensos, de forma semelhante, mas ainda menos desenvolvida, à de Howe, Khang e Chai (2019) para decisões judiciais em Singapura.

Contudo, a contribuição maior desta pesquisa reside na construção de um *corpus* que compila o texto relacionado a mais de 2000 PAS conduzidos pela CVM de maneira sistemática e replicável, que faculta aplicações posteriores alinhadas ou não aos objetivos iniciais do projeto de pesquisa.

5. Discussão e considerações finais

5.1. Limitações e desafios

Entre os desafios e limitações desta pesquisa em relação à sua aplicação destaca-se a anotação do *corpus*, realizada por apenas uma pessoa. Para contornar o problema, considerando que as anotações de relevância não seriam revisadas por terceiros (ou, idealmente, por uma equipe de anotação), optou-se por sinalizar claramente os casos limítrofes e também por coletar outras variáveis que fossem plenamente objetivas (se houve condenação e se foi pecuniária) para permitir testar em momento posterior a capacidade de previsão do modelo com mais observações.

A CVM não disponibilizou algumas informações da melhor forma possível. Ainda que os materiais estejam bem organizados para o período de interesse, alguns documentos em PDFs escaneados obrigaram a extrair texto, e para alguns, o relatório não estava disponível. Para atacar o primeiro problema, criou-se uma coluna indicando se o texto associado ao *corpus* tinha sido extraído de um documento escaneado; o segundo problema não teve impacto relevante, pois cerca de 10 processos não tinham o relatório disponível.

É possível argumentar que a quantidade de observações usadas para treinar os modelos foi insuficiente, mas as estatísticas obtidas são preliminares, e Howe, Khang e Chai (2019) mostram que o treinamento com menos de 600 processos é suficiente para mostrar bons resultados. Isso abre também a possibilidade de comparar os modelos treinados com 600 observações com os que são treinados por uma quantidade menor.

5.2. Síntese das contribuições

Apesar dessas limitações, a pesquisa tem o mérito de coletar sistematicamente e consolidar a estrutura de dados associada aos PAS da CVM de modo pioneiro, a exemplo do *corpus* criado e dos “produtos complementares” (nome de acusados, IDs, número de processos etc.). Os dados coletados podem ser utilizados em pesquisas futuras – de testes de efetividade de modelos de classificação aplicados aos documentos que se quer estudar até avaliações de políticas regulatórias no mercado de capitais brasileiro.

Por último, embora sejam preliminares e de natureza metodológica, os resultados dialogam diretamente com as teorias apresentadas. O desenvolvimento de um *corpus*

replicável e de ferramentas de PLN permite mensurar variáveis fundamentais para os modelos teóricos apresentados nas seções anteriores, contribuindo para estudos empíricos futuros.

5.3. Próximos passos da pesquisa

Os possíveis próximos passos da pesquisa podem ser divididos em duas frentes. A primeira diz respeito à anotação de uma parcela maior do *corpus*, ou classificação para outra variável de interesse que seja categórica. A segunda refere-se à comparação da performance dos modelos de classificação para diferentes estratos do *corpus* (por exemplo, comparar a performance de modelos treinados com números diferentes de observações). Se a performance do modelo for suficientemente boa, pode-se aplicá-lo aos textos não classificados, obtendo-se uma estimativa robusta do valor das variáveis de interesse, que pode ser usada posteriormente para análises econométricas.

A trajetória desta pesquisa ilustra o caráter inerentemente iterativo do trabalho com dados textuais e processamento de linguagem natural. O projeto passou por uma reorientação metodológica significativa durante seu desenvolvimento, na qual a descoberta das particularidades dos textos regulatórios da CVM e os desafios práticos da anotação levaram a ajustes tanto nos objetivos quanto nas estratégias de implementação. Tal redirecionamento reflete a natureza exploratória essencial da pesquisa com *corpus* linguísticos, em que a compreensão aprofundada dos dados frequentemente revela caminhos mais promissores do que aqueles inicialmente planejados, demonstrando que o processo de descoberta é tão valioso quanto os resultados finais obtidos.

Referências Bibliográficas

Aldrichi, Dante Mendes. 2011. “Risks of Wrongdoing in Public Companies and Ways to Cope with Them: The Case of Brazil”. Em: *International Handbook on the Economics of Corruption*, 2:231-265. Northampton: Edward Elgar Publishing.

Aldrichi, Dante Mendes, e Luiz Kabback de Castro. 2023. “Corporate Scandals in Brazil”. Em: *Corporate Governing in Latin America: The Importance of Scandals to Institute Change*, 247–270. Cham: Palgrave Macmillan.

Callund, Jonathan, Gonzalo Jiménez-Seminario e Neil Pyper. 2023. *Corporate Governing in Latin America: The Importance of Scandals to Institute Change*. Cham: Palgrave Macmillan.

Comissão de Valores Mobiliários (CVM). 2021. *Resolução CVM Nº45, de 31 de agosto de 2021*.

Comissão de Valores Mobiliários (CVM). 2025. “Sobre a CVM”. Comissão de Valores Mobiliários.

<https://www.gov.br/cvm/pt-br/aceso-a-informacao-cvm/institucional/sobre-a-cvm/sobre-a-cvm>.

Correa do Lago, Luis Aranha. 1989. “Uma revisão do período do ‘milagre’. Política econômica e crescimento, 1967-1973”. Textos para discussão 235. Department of Economics PUC-Rio.

Da Costa, Roberto Teixeira. 1985. *Brazil’s Experience in Creating a Capital Market*. São Paulo: Bovespa.

Dyck, Alexander, Adair Morse, e Luigi Zingales. 2010. “Who Blows the Whistle on Corporate Fraud?” *The Journal of Finance*, 65(6): 2213–53. <https://doi.org/10.1111/j.1540-6261.2010.01614.x>.

Dyck, Alexander; Adair Morse, e Luigi Zingales. 2023. “How pervasive is corporate fraud?” *Review of Accounting Studies*, 29: 736–69. <https://doi.org/10.1007/s11142-022-09738-5>.17

Dispõe sobre o mercado de valores mobiliários e cria a Comissão de Valores Mobiliários. 1976. Pub. L. No. 6385. https://www.planalto.gov.br/ccivil_03/leis/l6385.htm.

Grimmer, Justin, Margaret Roberts, e Brandon Stewart. 2022. *Text as Data: A New Framework for Machine Learning and the Social Sciences*. Princeton: Princeton University Press.

Howe, Jerrold Soh Tsin, Lim How Khang, e Ian Ernst Chai. 2019. “Legal Area Classification: A Comparative Study of Text Classifiers on Singapore Supreme Court Judgments”. arXiv preprint arXiv:1904.06470. <https://doi.org/10.48550/arXiv.1904.06470>.

Jensen, Michael, e William Meckling. 1976. “Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure”. *Journal of Financial Economics*, 3(4): 305–60. [https://doi.org/10.1016/0304-405X\(76\)90026-X](https://doi.org/10.1016/0304-405X(76)90026-X).

Johnson, Shane, Harley Ryan, e Yisong Tian. 2009. “Managerial Incentives and Corporate Fraud: The Sources of Incentives Matter”. *Review of Finance*, 13(1): 115–45. <https://doi.org/10.1093/rof/rfn014>.

Karpoff, Jonathan, Allison Koester, Scott D. Lee, e Gerald Martin. 2017. “Proxies and databases in financial misconduct research”. *The Accounting Review*, 92(6): 129–63. <https://doi.org/10.2308/accr-51766>.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2019. “Além dos números da CVM: Enforcement no mercado de capitais brasileiro - 1º semestre 2019”. São Paulo: FGV Direito SP.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2021. “Além dos números da CVM: Enforcement no Mercado de Capitais Brasileiro - 2021”. São Paulo: FGV Direito SP.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2022. “Além dos números da CVM: Enforcement no Mercado de Capitais Brasileiro - 2022”. São Paulo: FGV Direito SP.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2023. “Além dos números da CVM: Enforcement no Mercado de Capitais Brasileiro - 2023”. São Paulo: FGV Direito SP.

Wang, Tracy Yue. 2013. “Corporate Securities Fraud: Insights from a New Empirical Framework”. *The Journal of Law, Economics, and Organization*, 29(3): 535–68. <https://doi.org/10.1093/jleo/ewr009>.

Zingales, Luigi. 2002. “Corporate Governance”. Em: *The New Palgrave Dictionary of Economics and the Law*, 497–503. London: Palgrave Macmillan