



Universidade de São Paulo
Faculdade de Economia, Administração, Contabilidade e Atuária

**Fraudes Corporativas no Brasil: Atuação da CVM no
Enforcement do Arcabouço Regulatório-Legal dos Mercados de
Capital**

Relatório Parcial de Iniciação Científica

Nome: Tomás Peres Ribeiro

Orientador: Prof. Dr. Dante Aldrighi

Resumo

Quais são os incentivos e instituições que ditam a ocorrência das fraudes corporativas no Brasil? A pesquisa investiga suspeitas de irregularidades cometidas nos mercados de capital no Brasil entre 2000 e 2023 a partir dos Processos Administrativos Sancionadores (PAS) conduzidos pela CVM. Esses documentos trazem informações sobre a companhia envolvida, a dosimetria aplicada, a celebração ou não de um termo de compromisso (TC), as características da parte acusada e o tipo de malfeito supostamente cometido. Com essa base de dados, pretende-se examinar as potenciais influências de características das firmas (como tamanho, setor, estrutura de propriedade do capital, segmento de listagem na bolsa de valores e outros indicadores de governança) e do ambiente institucional (legislação e normas vigentes e capacidade de fiscalização e de *enforcement* da CVM) na ocorrência das fraudes corporativas.

Abstract

This project aims to investigate the suspected irregularities committed in Brazilian capital markets between 2000 and 2023, through the analysis of Sanctioning Administrative Processes driven by Brazilian Securities Commission during given period. These documents have information on the involved company, applicable punishments, celebration of settlement agreements, defendant's characteristics and supposedly committed wrongdoing. Using this database, we aim to examine potential influences that operating firms characteristics (such as size, sector, capital property structure, stock exchange listing segment and other governance indicators) and the institutional environment (applicable legislation and regulations and the SEC's enforcement power) may have on the occurrence of corporate fraud.

1. Introdução

O Decreto-lei nº 157, de 1967 tinha como objetivo incentivar a captação de recursos via emissão de ações de modo a sustentar a expansão de investimentos produtivos (Correa do Lago 1989, p. 74). Todavia, no contexto da fraca regulamentação dos mercados de capitais, o resultado foi a alta artificial dos preços das ações, “culminando com um *boom* especulativo seguido de um traumático processo de reajuste em 1971” (Costa 1985, p. 41-2). O processo de reajuste envolveu esforços para criar um arcabouço regulatório dos mercados de capitais e assegurar sua observância, de modo a proteger os investidores e proporcionar transparência nas informações das companhias.

Em 1976, instituiu-se a Lei nº 6385, que dispõe sobre o funcionamento do mercado de capitais no país (Brasil 1976) e foi criada a Comissão de Valores Mobiliários (CVM) , autarquia vinculada ao Ministério da Fazenda, “com o objetivo de fiscalizar, normatizar, disciplinar e desenvolver o mercado de valores mobiliários no Brasil” (CVM 2024).

Os Processos Administrativos Sancionadores (PAS), regulados pela Resolução nº 45 da autarquia, de agosto de 2021, constituem principal instrumento de *enforcement* das normas da CVM e também da legislação referente às empresas de capital aberto. Detectada uma ilegalidade, por quaisquer meios, a CVM pode instaurar um PAS, com base nos termos do Art. 5º (CVM 2021); segue-se a notificação dos acusados, que podem apresentar defesa; após sorteio de um relator, realiza-se uma Sessão de Julgamento, conduzida pelo Presidente da CVM, em que cada membro do Colegiado¹ tem direito a voto e as deliberações são tomadas por maioria. A CVM tem a prerrogativa de impor uma série de penalidades, isolada ou cumulativamente.

Em qualquer momento do andamento de um PAS, os acusados podem apresentar uma proposta de Termo de Compromisso (TC), pela qual se comprometem a cessar a prática de atividades consideradas ilícitas e, se for o caso, corrigir os prejuízos imputados. Após recomendação do Comitê de Termo de Compromisso (CTC)², o Colegiado delibera se aceita ou não a proposta de TC apresentada. No caso de aceitação e cumprimento da proposta de TC pela parte acusada, o PAS é suspenso.

A despeito dos grandes avanços na governança das empresas propiciados por importantes mudanças institucionais (como as reformas na lei das S.A. de 2001 e na lei

¹ O Colegiado da CVM é formado por um Presidente e quatro Diretores, nomeados pelo Presidente da República e aprovados pelo Senado Federal.

² O CTC é formado pelos titulares de cinco ou mais Superintendências da CVM (normalmente funcionários de carreira, que devem possuir pós-graduação na área), indicados pelo Presidente, além do titular da Procuradoria Federal Especializada na CVM (PFE-CVM).

relativa a títulos mobiliários de 2002, que fortaleceu a CVM; a criação pela B3, em 2000, de segmentos de listagem diferenciados de governança das empresas), fraudes corporativas (FCs) têm sido recorrentes nos mercados de valores mobiliários no Brasil. Parcela expressiva dos malfeitos corporativos concentra-se em casos de expropriação de acionistas minoritários por acionistas majoritários (controladores) e prepostos.

Esta pesquisa visa construir uma base de dados sobre os casos envolvendo este tipo de malfeito corporativo com base no exame sistemático das informações disponíveis nos PAS e nos TCs da CVM de 2000 a 2023.

Considerando a grande quantidade de dados qualitativos (linguísticos) e a necessidade de processamento individual de cada processo, optou-se pelo uso de ferramentas de aprendizado de máquina; na área de Processamento de Língua Natural; com o objetivo de classificar a relevância dos processos em consonância com o critério descrito acima. O uso destas ferramentas, informado pelo arcabouço teórico apresentado posteriormente, exige a um *corpus* para aplicações em Processamento de Língua Natural (PLN) na área de FCs no Brasil. Feito isso, serão empregadas técnicas econométricas para investigar os fatores que influenciam a ocorrência de FCs bem como identificar possíveis mecanismos de governança que as inibam ou as impeçam.

Como os PAS e TCs da CVM são uma fonte rica, confiável e relativamente padronizada de informações sobre FCs no Brasil, a base de dados construída pode gerar evidências sistêmicas para investigar questões de interesse acadêmico e de *policy-makers*, como as características das empresas e do mercado de valores mobiliários que se conectam com malfeitos corporativos e a influência das reformas institucionais sobre os incentivos dos controladores, investidores e executivos.

2. Referencial Teórico

2.1. O arcabouço teórico

A persistência das fraudes corporativas no país pode ser entendida pela ótica do clássico modelo econômico do crime de Becker (1968), em que o agente confronta as utilidades esperadas do ato criminoso e do emprego de tempo e outros recursos em atividades alternativas (ex.: trabalho remunerado lícito). Isso implicaria, portanto, na “existência de uma função que relaciona o número de ofensas cometidas por uma pessoa com a sua probabilidade de ser condenado, a sua pena, caso condenado, e outras variáveis, como a renda disponível em

outras atividades (legais e ilegais) e sua disposição pessoal em cometer um ato ilícito.” (Becker 1968, p. 9).

A Teoria da Agência, formulada por Jensen e Meckling (1976), focaliza mais claramente alguns elementos que interferem nas utilidades esperadas dos indivíduos no contexto da firma. Segundo esta teoria, uma relação de agência ocorre quando um indivíduo ou grupo (o principal) contrata outro indivíduo ou grupo (o agente) para desempenhar uma atividade em seu nome, delegando-lhe algum grau de tomada de decisão. Essa delegação de autoridade, dos acionistas para os executivos, embora essencial para a operação eficiente das empresas, cria um “problema de agência” devido ao desalinhamento potencial entre os interesses do principal e do agente.

Como os gestores possuem informações mais detalhadas sobre a empresa do que os acionistas minoritários (assimetria informacional), podem tomar decisões que maximizam seu próprio bem-estar às custas dos acionistas minoritários, como adotar projetos de menor risco para preservar seus empregos e manipular resultados contábeis para maximizar bônus de desempenho. Neste contexto, surgem os custos de agência, que representam a soma dos custos relacionados ao problema de agência: as perdas diretas decorrentes da extração de benefícios privados pelos executivos que destroem valor corporativo, adicionados às despesas incorridas para inibir tal comportamento oportunista.

Os autores atribuem grande peso ao papel da estrutura de propriedade na intensidade do problema de agência. Na relação de agência, o monitoramento dos executivos é um bem público, que exige esforço de cada acionista. Estes, no entanto, não têm incentivo individual para exercê-lo, uma vez que o custo incorrido para o monitoramento é individual e o benefício se estende aos demais acionistas (*free-riding*). Neste caso, portanto, a concentração da propriedade poderia mitigar o conflito de agência, uma vez que acionistas com participação significativa internalizam uma parcela maior dos benefícios decorrentes do monitoramento da gestão. Isso reduz o problema de *free-riding* e incentiva a supervisão ativa dos executivos, reduzindo comportamentos oportunistas e garantindo que as decisões de gestão estejam alinhadas com os interesses da empresa.

Zingales (2002) aprofunda a discussão dos problemas de agência ao analisá-los sob a ótica dos contratos incompletos. Como os contratos são incapazes de prever todas as contingências futuras, não se pode especificar plenamente o que cada agente (executivo) deve fazer no futuro. Desta forma, eles podem exercer poder discricionário, o que pode levar à extração de benefícios privados da empresa em detrimento dos acionistas.

Além disso, cada *stakeholder* realiza investimentos específicos na empresa, tornando

suas transações únicas e não padronizadas. Isso gera *quasi-rents* (excedentes) cuja divisão não pode ser determinada antecipadamente por contrato. Assim, ocorre uma barganha *ex post* entre as partes envolvidas. A governança corporativa, portanto, consiste no conjunto de regras que molda como o poder e, conseqüentemente, as *quasi-rents* são distribuídas entre os *stakeholders*, já que altera os incentivos de cada um dos deles no processo de barganha.

Com base nisso, fica evidente que a análise da atuação da CVM e das mudanças no arcabouço regulatório e outras alterações institucionais no mercado de capitais, enquanto parte relevante do sistema de governança corporativa brasileiro, possibilitará uma investigação aprofundada sobre como inibir a ocorrência de FCs, podendo contribuir para o desenho de políticas regulatórias do mercado de capitais no Brasil..

2.2. Trabalhos relacionados

Embora recorrentes, as FCs têm sido pouco investigadas no país, em contraste com a copiosa literatura para mercados desenvolvidos, como Estados Unidos e União Europeia.

Dyck, Morse e Zingales (2010) investigam a identidade, características e incentivos dos *whistleblowers* que denunciam práticas ilícitas nas empresas norte-americanas. A base de dados que utilizam contém variáveis sobre o tipo de denunciante (se autoridades regulatórias dos mercados de capital ou setoriais, auditores, jornalistas, empregados etc.), seus incentivos (profissionais, reputacionais e monetários) e o grau de acesso a informações privilegiadas.

Obtém evidências da importância, entre os denunciantes, de agentes não convencionais (mídia e funcionários das empresas) *vis-à-vis* aqueles cuja atribuição de ofício é exercer tal monitoramento, como órgãos reguladores e fiscalizadores e auditores. Além disso, analisam com detalhe os incentivos e *tradeoffs* enfrentados por categoria de denunciante (por exemplo, no caso de o *whistleblower* ser um funcionário da empresa, o risco de perder o emprego ou de ser relegado ao ostracismo pelos colegas. Observam que os incentivos monetários são especialmente importantes para os funcionários do setor de saúde e os incentivos reputacionais, para jornalistas.

Wang (2013) e Dyck, Morse e Zingales (2023) estimam a probabilidade de detecção de FCs a partir de medidas de fraudes observadas. Dyck, Morse e Zingales (2023) recorrem a um experimento natural: após um escândalo em uma auditoria, as empresas que eram anteriormente suas clientes passaram a ser mais fiscalizadas, o que aumentou o grau de FCs detectadas. A partir disso, os autores estimam que somente um terço das fraudes corporativas é detectada.

Por sua vez, Johnson, Ryan e Tian (2009) focalizam os incentivos dos executivos e a probabilidade de ocorrência e detecção de FCs. Utilizando uma base de dados construída a partir de informações sobre os malfeitos investigados pela *Securities and Exchange Commission* (SEC), a CVM norte-americana, entre 1992 e 2005, realizam o pareamento (*matching*) com empresas não-fraudulentas e encontram evidências de que malfeitos corporativos tendem a ser mais frequentes em empresas cuja remuneração dos executivos é atrelada preponderantemente ao desempenho das ações, resultados consistentes com Becker (1968).

Karpoff et al. (2017) identificam quatro bases de dados entre as mais utilizadas para estudar FCs nos Estados Unidos, examinando as vantagens e desvantagens de cada uma delas. Chamam atenção para os cuidados que se devem ter ao utilizá-las e para a importância dos dados colhidos manualmente “para aliviar os problemas que surgem quando uma base de dados ou uma variável proxy em específico é utilizada para identificar uma amostra de malfeitos ocorridos” (Karpoff et al. 2017, p. 43). Enfatizam, também, a importância da replicabilidade da construção das bases de dados e a relevância de que tenham uma construção iterativa. Como os resultados são muito sensíveis à base de dados utilizada, recomendam testes de validade externa para as bases de dados construídas.

Os trabalhos acima fundamentaram-se em bases de dados de FCs nos Estados Unidos. Por apresentar características institucionais únicas, como alta concentração de propriedade do capital e arcabouço regulatório e mecanismos de *enforcement* menos robustos, o contexto corporativo brasileiro torna imprescindível uma análise específica.

Aldrighi (2011) e Aldrighi e Kabback de Castro (2023) empreendem estudos empíricos descritivos sobre FCs no país, focalizando um número limitado de empresas e empregando informações de diversas fontes, o que permite um entendimento mais aprofundado de casos específicos. Callund, Jiménez-Seminario e Pyper (2023) examinam o contexto institucional de alguns países da América Latina. Alguns trabalhos fazem um esforço no sentido de construir relações parecidas para o Brasil, embora usem bases de dados menos abrangentes. O Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap), da FGV-SP, divulga relatórios anuais sobre os PAS conduzidos pela CVM (MFCap 2019, 2021, 2022), categorizando todas as ocorrências julgadas pela CVM e organizando os dados pela perspectiva jurídica para os anos de 2019, 2021 e 2022. Diferentemente, o presente trabalho tem como propósito explorar de modo detalhado o conjunto das informações disponíveis pelo

recorte específico de tentativas de expropriação de acionistas minoritários pelos acionistas controladores para um período de 24 anos (2000-2023).

3. Método (ou Desenvolvimento do Trabalho ou Etapas da Pesquisa)

3.1. Critérios para a construção da base de dados

A base de dados será construída a partir de informações disponíveis no site oficial da CVM e de duas fontes principais: os Extratos das Sessões de Julgamento³, documentos que registram o voto dos relatores e um relato dos acontecimentos, e os Pareceres do Comitê de Termo de Compromisso⁴, em que ficam registradas as negociações entre as partes no acordo de um TC.

Optou-se por separar a construção da base de dados em duas etapas metodológicas: classificação da relevância, ou seja, a decisão de incluir ou não o processo na base de dados; e extração dos valores das variáveis para cada do processo incluído na base de dados.

Para a primeira parte, optou-se pelo uso de ferramentas de Processamento de Língua Natural, especificadas na subseção seguinte. Os critérios para definir um processo como “relevante” são:

1. Recorte temporal: o julgamento do processo aconteceu entre 2000 e 2023.

2. Tipo de malfeito: o foco do projeto está restrito às supostas tentativas de expropriação de recursos de acionistas minoritários pelos acionistas controladores, subvertendo o funcionamento regular da companhia envolvida. Isso implica na exclusão de processos relacionados, por exemplo, à má-gestão de fundos ou corretoras ou inadequações contábeis de natureza formal e sem impacto distributivo.

Para a segunda etapa metodológica, após a exclusão dos processos não relevantes, será feita a coleta de um conjunto de 23 variáveis, já definidas, para cada acusado, parte das quais procedimentais, como indica a Tabela 1.

³ Disponíveis em <https://conteudo.cvm.gov.br/decisoes/pesquisa/pesquisa.html>.

⁴ Para as propostas aceitas, o endereço é: <https://conteudo.cvm.gov.br/termoscompromisso/index.html>. Para as rejeitadas, <https://conteudo.cvm.gov.br/termoscompromissorejeitados/index.html>.

Variável	Descrição
Identificador do processo (<i>process_id</i>)	O código de identificação do processo, definido pela CVM.
Identificador do acusado (<i>defendant_id</i>)	Número associado ao acusado, ordenando os acusados em ordem alfabética.
Início do processo (<i>instauration_date</i>)	Data de instauração do PAS.
Final do processo (<i>end_date</i>)	Data da Sessão de Julgamento do PAS.
Link de acesso (<i>access_link</i>)	Link de acesso à página do processo no site da CVM.
Nome (<i>firm_name</i>)	Razão social da companhia envolvida, registrada oficialmente nos autos do PAS.
Ticker (<i>firm_ticker</i>)	Abreviação do ticker da companhia envolvida, caso estivesse listada publicamente no mercado de ações à época do ocorrido.
Valor dos ativos (<i>firm_assets</i>)	Valor total divulgado dos ativos da companhia envolvida no ano anterior à abertura do PAS. No caso de falência, o último disponível.
Data do IPO (<i>firm_ipo</i>)	Data em que a companhia envolvida foi listada publicamente na bolsa.
Houve aplicação de penalidade (<i>penalty</i>)	Variável dummy que assume 1 se o indivíduo foi condenado e 0, caso contrário.
Tipo de penalidade (<i>penalty_type</i>)	Variável categórica que indica o tipo de penalidade aplicada. Pode assumir os valores: advertência (1); multa (2); inabilitação temporária para cargo de administração (3); suspensão total (4); suspensão parcial (5).
Valor da multa (<i>fine_value</i>)	Valor da multa pecuniária aplicada pela CVM sobre o condenado, em moeda corrente no momento da condenação.
Houve proposta de TC? (<i>settlement_proposal</i>)	Variável binária que assume o valor 1 se o acusado apresentou proposta de TC, e 0 caso contrário.
O TC foi celebrado? (<i>settlement_celebrated</i>)	Variável binária que assume o valor 1 se a CVM, mesmo que após contraproposta, optou por celebrar TC e portanto, absolver o acusado, e 0 caso contrário.
Valor da proposta inicial (<i>initial_set_value</i>)	Valor associado à primeira proposta de TC realizada pelo acusado, em moeda corrente no momento da realização da proposta.

Valor do compromisso final firmado (<i>final_set_value</i>)	Valor associado à quantidade paga, de fato, pelo acusado depois de contraproposta (ou não) da CVM, em moeda corrente no momento da aceitação do compromisso.
Categoria jurídica do acusado (<i>is_pf</i>)	Variável binária que assume o valor 1 se a parte acusada é Pessoa Física, e 0 caso contrário.
Cargo do acusado (<i>defendant_post</i>)	Variável que, quando o acusado é categorizado como pessoa física, pode assumir os seguintes valores: conselho de administração (1); diretoria executiva (2); stakeholders, divididos em fornecedores (3), credores (4), consumidores (5) e acionistas (6); funcionários não executivos (7).
Acusado é presidente? (<i>is_chairman</i>)	Variável binária que, para membros do conselho de administração ou da diretoria executiva, assume valor 1 se o acusado é presidente do conselho/diretoria e 0, caso contrário.
Número de acusados (<i>number_defendants</i>)	O número de acusados no processo em que o acusado foi inserido, incluindo o próprio acusado.
Duração do malfeito (<i>offense_duration</i>)	Duração, em meses, do malfeito, conforme descrito nos autos do processo.
Grupo da infração (CVM) (<i>offense_group</i>)	Variável categórica que indica o grupo da infração, de acordo com o Art. 62 da resolução No 45 da CVM, de agosto de 2021.
Meio para a concretização da expropriação (<i>expropriation_means</i>)	Variável categórica que indica o meio pelo qual os acionistas controladores expropriaram os minoritários. As categorias são: fraude contábil ou na auditoria (1); problemas na divulgação de fato relevante (2); uso de informação privilegiada (insider trading) (3); manipulação de preços e/ou criação de condições artificiais (4); oferta pública sem registro (5); violação do dever de diligência (6); self dealing e/ou tunneling (7); arbitragem regulatória (8); aquisições/fusões fraudulentas (9); distribuição errônea de dividendos (10).

Tabela 1: consolidação com as variáveis a serem extraídas dos processos.

3.2. Métodos práticos para a construção da base de dados e Processamento de Língua Natural

A construção da base de dados envolve o tratamento de uma grande quantidade de dados, com documentos extensos e em grande quantidade. Por isso, optou-se por aplicar métodos de Processamento de Língua Natural (PLN) com o objetivo de classificar a relevância, segundo os critérios definidos acima. Para isso, deve-se construir um (ou mais) *corpus*, termo que designa um conjunto de dados linguísticos e equivale à extração de uma amostra de uma população de dados linguísticos.

A construção do *corpus* será feita pela extração automatizada de trechos do Relatório ou do Parecer do CTC para cada PAS, empregando-se um código em *Python*, baseado em expressões regulares, que extrai os trechos relevantes de cada dos processo, aliado a técnicas de *web-scraping*.

Procede-se, então, à anotação manual do *corpus*, que requer a definição de critérios objetivos para avaliar a relevância dos PAS, isto é, a definição formal das expressões linguísticas consideradas suficientes para caracterizar um processo como relevante ou não. Trata-se de uma etapa pivotal do método, que permite garantir a replicabilidade da anotação, para que, quaisquer que sejam os anotadores, os resultados sejam semelhantes.

A partir do *corpus* anotado, aplicam-se aos dados modelos de aprendizado de máquina (ML) supervisionados e não-supervisionados para avaliar uma série de modelos que possam ser utilizados para classificar a relevância dos PAS. Dentre os modelos que se pretende avaliar, destacam-se os seguintes: *Support Vector Machines*, *Decision Trees*, Modelos Linguísticos Binomiais, *Random Forests*, *BERTs* e *GPTs*.

Haverá quatro etapas: 1) Pré-processamento (*tokenização*); 2) Separação em grupos de treino e teste; 3) Treinamento do modelo; e 4) Avaliação de métricas de qualidade (acurácia, precisão, *recall* e *f1-score*). Isso feito, realiza-se o *fine-tuning* dos modelos: a escolha dos hiperparâmetros (*maximum depth*, *n-gram*, *epochs*, taxa de aprendizado etc.) que maximizam a qualidade do modelo, permitindo-se identificar o mais adequado para classificar a relevância dos PAS e aplicá-lo ao restante da base de dados, de forma a obter a relevância de cada processo.

Feita a classificação para cada PAS, extraem-se as 23 variáveis de interesse citadas anteriormente. A princípio, a extração será conduzida manualmente, em função de ser, para boa parte das variáveis escolhidas, simples e objetiva. Todavia, podem ser empregados métodos de *information extraction* (IE) para algumas das variáveis. Para as variáveis

categóricas, é possível usar modelos de classificação semelhantes aos citados nos parágrafos anteriores. Para analisar as demais variáveis, predominantemente quantitativas, seria necessário, provavelmente, utilizar-se de *GPTs* (*Generative Pre-trained Transformers*), mais indicados para esse tipo de extração de dados estruturados a partir de documentos linguísticos não estruturados. Existem pacotes de processamento voltados à área jurídica brasileira que fazem algo semelhante (Polo et al. 2021), e aplicações similares já foram feitas por estudos em outros países (Bommarito, Katz e Detterman 2021; Pudasaini et al. 2021; Zadgaonka e Agrawal 2021).

O emprego de ferramentas de PLN para classificar a relevância configura uma contribuição no que diz respeito à extração, construção e análise de dados sobre FCs, PAS e a atuação da CVM. Ademais, a base de dados possibilitará a investigar fatores associados à ocorrência das FCs no país.

3.3. Potenciais usos da base de dados

A base de dados construída a partir dos PAS e dos TCs tem o potencial de, conjugada a outras bases de dados, confrontar a ocorrência, a gravidade, a punição e outras variáveis relacionadas a FCs com características das empresas (como tamanho, gastos com investimentos, endividamento e mecanismos de governança internos – estrutura de propriedade do capital, existência ou não de controlador, composição dos conselhos, adesão ou não ao Novo Mercado etc.). Dada a natureza longitudinal dos dados, também poderá relacionar dados sobre FCs com alterações na legislação das S.A. e nas normas e no poder de *enforcement* da CVM. Não se conhece a existência de uma base de dados sobre FCs no Brasil com tal grau de granularidade.

Os métodos para a investigação dessas possíveis conexões ainda não estão definidos. A evolução do processo de construção da base de dados evidenciará os procedimentos empíricos mais promissores, por exemplo, *matching*, controle sintético ou *regression discontinuity design* (RDD).

4. Resultados Parciais

4.1. Resultados esperados

Concluída a classificação de relevância para todos os processos, que ocorrerá provavelmente em junho, projetamos a extração das variáveis apresentadas na Tabela 1 para os processos correspondentes a um intervalo de dois anos. Outra possibilidade é focar os esforços na extração de uma ou mais variáveis específicas (exemplo: somente valor das penalidades), para processos correspondentes a um intervalo de tempo mais extenso.

Quanto à investigação dos possíveis fatores que afetam a ocorrência das FCs, por exigir uma diversidade maior de dados, provavelmente não será realizada nos seis meses restantes à bolsa. Contudo, serão apresentadas estatísticas descritivas de interesse com base nos dados já coletados.

4.2. Resultados parciais

Os resultados parciais obtidos até o momento estão relacionados sobretudo à etapa de preparação metodológica da pesquisa, abrindo o caminho para a execução. Confrontados com a grande quantidade de dados linguísticos, de difícil processamento (mais de 2000 processos, já listados), foi importante delimitar-se claramente os dados que a pesquisa busca extrair e como extraí-los.

A definição formal do primeiro ponto, com os critérios para cada variável, foi discutida e formalizada em um documento, *Codebook*, cujo objetivo é descrever o processo de construção da base de dados. Os critérios usados foram informações cuja extração não fosse demasiadamente difícil do ponto de vista técnico, e que pudessem servir como variáveis independentes no momento de testar correlações entre os elementos já descritos, o que está representado formalmente na Tabela 1.

Optou-se por usar as técnicas de PLN citadas anteriormente para classificar a relevância dos processos, mantendo a extração dos dados, a princípio, como um processo manual, depois da delimitação da relevância pelos modelos apresentados.

Foram construídos também códigos para extrair automaticamente de cada PAS informações procedimentais. Parte dos PAS não conta com cabeçalho para extração das informações – uma avaliação preliminar com 20 processos selecionados aleatoriamente apontou que quatro não estavam padronizados. Não obstante, os códigos se mostraram eficientes na coleta automática de informações em pelo menos 1000 dos 1271 Extratos de Sessões de Julgamento disponíveis no site da CVM⁵. Os dados coletados automaticamente por

⁵ Para assegurar a replicabilidade pelos pares, códigos, bases de dados e o Codebook estão disponíveis no repositório: <https://github.com/tomasrribeiro/corporate-fraud-in-brazil>.

processos de *web-scraping* e pelo uso de expressões regulares foram: Ementa/Assunto, Decisão, Número do processo, Data de julgamento e Nome dos compromitentes/acusados.

Como apoio ao processo de anotação, está em fase final de elaboração um documento com a delimitação explícita dos critérios que devem ser seguidos para garantir a universalidade e replicabilidade do processo de classificação manual da relevância dos PAS. Tal documento também está disponível no repositório (*Github*) e será incorporado posteriormente ao *Codebook*, por fazer parte do processo de construção da base de dados.

Esse processo tem se revelado iterativo e dinâmico, com colunas referentes a determinados tipos de dados e informações sendo incluídas ou removidas, o que é esperado, como apontam estudos que usam texto como dados. Grimmer, Roberts e Stewart (2022) assinalam que “aprendemos mais nas ciências sociais quando refinamos iterativamente os conceitos e as medidas, melhorando o nosso próprio entendimento das definições à medida em que somos expostos a novos dados.”

5. Considerações Finais e Próximos Passos

O objetivo maior desta pesquisa em questão reside na construção da base de dados que permita investigar fatores que influenciam a ocorrência das fraudes corporativas no Brasil em que ocorre a expropriação de minoritários pelos controladores. Para isso, pretende-se utilizar técnicas de PLN para classificar a relevância dos processos e, posteriormente, fazer a extração manual de variáveis de interesse.

Até o momento, foram delimitadas as variáveis de interesse e seus respectivos critérios, associados à construção de códigos que extraem automaticamente algumas informações. Além disso, contextualizaram-se os métodos para extração das variáveis, e iniciadas sua execução (extração de trechos que podem ser utilizados no *corpus* e delimitação formal dos critérios de anotação).

Esperam-se contribuições em duas frentes. A primeira é principalmente metodológica: o uso de métodos de PLN para a construção de bases de dados no ambiente da governança corporativa brasileira, que é inédito e possibilita a agilização e o processamento de grandes quantidades de dados com maior facilidade, sendo especialmente útil na área de análise de processos relacionados às falhas de governança.

A segunda contribuição é a investigação dos fatores que influenciam a ocorrência das FCs no Brasil. Construída a base de dados, e usando as técnicas econométricas pertinentes, pode-se confrontar tal ocorrência com características das empresas (tamanho, estrutura de

propriedade do capital etc.) e institucionais (atuação da CVM, leis em vigor etc.). Esse tipo de análise é de especial interesse para estudiosos e *policy-makers* na área de desenho e implementação de políticas públicas de combate a fraudes corporativas.

À luz do exposto, as próximas etapas da pesquisa priorizam a construção de um *corpus*, que compreende tanto a definição dos trechos extraídos (relatório, voto, assunto, decisão) para treinar os modelos, quanto a construção dos códigos que vão extraí-los dos documentos. Em seguida, a anotação do *corpus* com base nos critérios definidos anteriormente será feita para, a princípio, 200 processos, que servirão como grupos de treino e teste (e possivelmente validação).

Depois, é necessário treinar os modelos de classificação de relevância, o que inclui extrair métricas relevantes como acurácia e precisão, e posteriormente generalizar as previsões do modelo para todos os processos na base de dados. Feito isso, esperamos fazer a extração manual das variáveis de interesse para uma parte dos processos, correspondente a ao menos dois anos.

Evidentemente, a pesquisa apresenta algumas limitações: a relativa dificuldade na coleta das variáveis, que, apesar de ser um trabalho simples e dinâmico, demanda tempo devido à grande quantidade de dados; dadas as limitações na capacidade de monitoramento da CVM, provavelmente nem todos os ilícitos reportados ocorreram de fato e evidentemente tampouco todos os ilícitos que ocorreram durante o período foram detectados e investigados. Mesmo com essas ressalvas, a construção da base de dados a partir dos PAS e dos TCs constituirá uma contribuição importante: converter um volume enorme de informações qualitativas complexas em informações quantitativas mais facilmente manipuláveis.

Em suma, a pesquisa tem avançado de maneira satisfatória e potencial para contribuir metodologicamente e substantivamente, a despeito da grande quantidade de dados que devem ser processados em um curto intervalo de tempo.

Referências Bibliográficas

Aldrichi, Dante Mendes. 2011. “Risks of Wrongdoing in Public Companies and Ways to Cope with Them: The Case of Brazil”. Em: *International Handbook on the Economics of Corruption*, 2:231-265. Northampton: Edward Elgar Publishing.

Aldrichi, Dante Mendes, e Luiz Kabback de Castro. 2023. “Corporate Scandals in Brazil”. Em: *Corporate Governing in Latin America: The Importance of Scandals to Institute Change*, 247–270. Cham: Palgrave Macmillan.

Bommarito, Michael, Daniel Martin Katz, e Eric Detterman. 2021. “LexNLP: Natural language processing and information extraction for legal and regulatory texts”. Em: *Research Handbook on Big Data Law*, 216-27. London: Edward Elgar Publishing.

Callund, Jonathan, Gonzalo Jiménez-Seminario e Neil Pyper. 2023. *Corporate Governing in Latin America: The Importance of Scandals to Institute Change*. Cham: Palgrave Macmillan.

Comissão de Valores Mobiliários (CVM). 2021. *Resolução CVM Nº45, de 31 de agosto de 2021*.

Comissão de Valores Mobiliários (CVM). 2025. “Sobre a CVM”. Comissão de Valores Mobiliários.
<https://www.gov.br/cvm/pt-br/aceso-a-informacao-cvm/institucional/sobre-a-cvm/sobre-a-cvm>.

Correa do Lago, Luis Aranha. 1989. “Uma revisão do período do ‘milagre’. Política econômica e crescimento, 1967-1973”. Textos para discussão 235. Department of Economics PUC-Rio.

Da Costa, Roberto Teixeira. 1985. *Brazil’s Experience in Creating a Capital Market*. São Paulo: Bovespa.

Dyck, Alexander, Adair Morse, e Luigi Zingales. 2010. “Who Blows the Whistle on Corporate Fraud?” *The Journal of Finance*, 65(6): 2213–53.
<https://doi.org/10.1111/j.1540-6261.2010.01614.x>.

Dyck, Alexander; Adair Morse, e Luigi Zingales. 2023. “How pervasive is corporate fraud?” *Review of Accounting Studies*, 29: 736–69. <https://doi.org/10.1007/s11142-022-09738-5>.

Dispõe sobre o mercado de valores mobiliários e cria a Comissão de Valores Mobiliários. 1976. Pub. L. No. 6385. https://www.planalto.gov.br/ccivil_03/leis/l6385.htm.

Grimmer, Justin, Margaret Roberts, e Brandon Stewart. 2022. *Text as Data: A New Framework for Machine Learning and the Social Sciences*. Princeton: Princeton University Press.

Jensen, Michael, e William Meckling. 1976. “Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure”. *Journal of Financial Economics*, 3(4): 305–60.
[https://doi.org/10.1016/0304-405X\(76\)90026-X](https://doi.org/10.1016/0304-405X(76)90026-X).

Johnson, Shane, Harley Ryan, e Yisong Tian. 2009. “Managerial Incentives and Corporate Fraud: The Sources of Incentives Matter”. *Review of Finance*, 13(1): 115–45.
<https://doi.org/10.1093/rof/rfn014>.

Karpoff, Jonathan, Allison Koester, Scott D. Lee, e Gerald Martin. 2017. “Proxies and databases in financial misconduct research”. *The Accounting Review*, 92(6): 129–63. <https://doi.org/10.2308/accr-51766>.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2019. “Além dos números da CVM: Enforcement no mercado de capitais brasileiro - 1º semestre 2019”. São Paulo: FGV Direito SP.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2021. “Além dos números da CVM: Enforcement no Mercado de Capitais Brasileiro - 2021”. São Paulo: FGV Direito SP.

Núcleo de Estudos em Mercados Financeiro e de Capitais (MFCap). 2022. “Além dos números da CVM: Enforcement no Mercado de Capitais Brasileiro - 2022”. São Paulo: FGV Direito SP.

Polo, Felipe Maia, Gabriel Caiaffa Floriano Mendonça, Kauê Capellato J. Parreira, Lucka Gianvechio, Peterson Cordeiro, Jonathan Batista Ferreira, Leticia Maria Paz de Lima, Antônio Carlos do Amaral Maia, e Renato Vicente. 2021. “LegalNLP - Natural Language Processing Methods for the Brazilian Legal Language”. Em: *Anais do 18º Encontro Nacional de Inteligência Artificial e Computacional (ENIAC 2021)*, 763–74. Porto Alegre: Sociedade Brasileira de Computação. <https://doi.org/10.5753/eniac.2021.18301>.

Pudasaini, Shushanta, Subarna Shakya, Sagar Lamichhane, Sajjan Adhikari, Aakash Tamang, e Sujan Adhikari. 2022. “Application of NLP for Information Extraction from Unstructured Documents”. Em: *Lecture Notes in Networks and Systems*, 209: 695–704. Singapore: Springer.

Wang, Tracy Yue. 2013. “Corporate Securities Fraud: Insights from a New Empirical Framework”. *The Journal of Law, Economics, and Organization*, 29(3): 535–68. <https://doi.org/10.1093/jleo/ewr009>.

Zadgaonka, Ashwini, e Avinash Agrawal. 2021. “An overview of information extraction techniques for legal document analysis and processing”. *International Journal of Electrical and Computer Engineering*, 11(6): 5450–57.18

Zingales, Luigi. 2002. “Corporate Governance”. Em: *The New Palgrave Dictionary of Economics and the Law*, 497–503. London: Palgrave Macmillan